

Trabajo Práctico – IECD

Grupo 11

2025-12-08

Introducción

Objetivo del trabajo

Análisis de propiedades estadísticas de tests diagnósticos:

1. **Test perfecto** (baseline)
2. **Test imperfecto** con S_e y S_p conocidos
3. **Dos muestras** (pre-post intervención)

Parte I

Test perfecto (baseline)

1.1 Distribución de T_{per}

Motivación

- ▶ Estudiamos primero un caso ideal: el test diagnóstico **no comete errores**.
- ▶ Esto equivale a suponer:

$$Se = 1, \quad Sp = 1.$$

- ▶ En este escenario, el resultado del test coincide exactamente con el estado verdadero Y .
- ▶ Objetivo del punto 1.1:

Mostrar que $T_{per} \sim \text{Binomial}(n, \theta)$.

Modelo del estado verdadero

- ▶ Cada individuo i puede estar enfermo ($Y_i = 1$) o sano ($Y_i = 0$).
- ▶ Modelamos:

$$Y_i \sim \text{Bernoulli}(\theta), \quad i = 1, \dots, n,$$

donde $\theta = P(Y = 1)$ es la prevalencia verdadera.

Número de individuos enfermos en la muestra

- Definimos:

$$T_{per} = \sum_{i=1}^n Y_i.$$

- Interpretación:

- T_{per} cuenta la cantidad de personas enfermas en la muestra.
- Es la suma de n variables Bernoulli independientes con el mismo parámetro θ .

Resultado

- ▶ La suma de n variables Bernoulli independientes con parámetro θ sigue una binomial:

$$T_{per} \sim \text{Binomial}(n, \theta).$$

- ▶ Para $k = 0, 1, \dots, n$:

$$P(T_{per} = k) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}.$$

De esta forma, $T_{per} \sim \text{Binomial}(n, \theta)$

1.2 Estimador de Máxima Verosimilitud

Planteo

- ▶ Seguimos en el caso de **test perfecto**:

$$Y_i \sim \text{Bernoulli}(\theta), \quad i = 1, \dots, n,$$

independientes e idénticamente distribuidas.

- ▶ Definimos:

$$T_{per} = \sum_{i=1}^n Y_i.$$

- ▶ Nuestro objetivo en este punto es encontrar el **estimador de máxima verosimilitud (EMV)** de θ .
- ▶ Notación útil:
 - ▶ $N_1 = \sum_{i=1}^n Y_i = T_{per}$: número de enfermos en la muestra.
 - ▶ $N_0 = n - N_1$: número de sanos en la muestra.

Función de verosimilitud

- Dada la muestra Y_1, \dots, Y_n , la función de verosimilitud es:

$$L(\theta) = \prod_{i=1}^n P_\theta(Y_i) = \prod_{i=1}^n \theta^{Y_i} (1-\theta)^{1-Y_i}.$$

- Reagrupando términos:

$$L(\theta) = \theta^{\sum_{i=1}^n Y_i} (1-\theta)^{\sum_{i=1}^n (1-Y_i)} = \theta^{N_1} (1-\theta)^{N_0}.$$

- Trabajamos con la **log-verosimilitud**:

$$\ell(\theta) = \log L(\theta) = N_1 \log(\theta) + N_0 \log(1-\theta).$$

- ▶ Derivamos la log-verosimilitud respecto de θ :

$$\ell'(\theta) = \frac{d}{d\theta} [N_1 \log(\theta) + N_0 \log(1 - \theta)] = \frac{N_1}{\theta} - \frac{N_0}{1 - \theta}.$$

- ▶ Buscamos $\hat{\theta}$ tal que $\ell'(\hat{\theta}) = 0$:

$$\frac{N_1}{\hat{\theta}} - \frac{N_0}{1 - \hat{\theta}} = 0 \implies \frac{N_1}{\hat{\theta}} = \frac{N_0}{1 - \hat{\theta}}.$$

- ▶ Despejando:

$$N_1(1 - \hat{\theta}) = N_0\hat{\theta} \implies N_1 = (N_0 + N_1)\hat{\theta} = n\hat{\theta}.$$

- ▶ Por lo tanto:

$$\hat{\theta}_{per} = \frac{N_1}{n}.$$

Verificación de máximo e interpretación

- ▶ Segunda derivada:

$$\ell''(\theta) = -\frac{N_1}{\theta^2} - \frac{N_0}{(1-\theta)^2} < 0 \quad \text{para todo } \theta \in (0, 1).$$

- ▶ Luego, el punto crítico encontrado corresponde a un **máximo global** de la verosimilitud.
- ▶ Como $N_1 = T_{per}$, podemos escribir:

$$\hat{\theta}_{per} = \frac{N_1}{n} = \frac{T_{per}}{n}.$$

Interpretación

- ▶ El EMV de θ es simplemente la **proporción muestral de individuos enfermos**.
- ▶ En el caso de test perfecto, el estimador natural de la prevalencia es la cantidad de enfermos observados / tamaño de la muestra.

1.3 Sesgo, Varianza, Error cuadrático medio, consistencia y distribución asintótica

► Sesgo:

El estimador $\hat{\theta}_{per} = \frac{T_{per}}{n}$ es insesgado porque

$$\mathbb{E}[\hat{\theta}_{per}] = \mathbb{E}\left[\frac{T_{per}}{n}\right] = \frac{1}{n}\mathbb{E}[T_{per}] = \frac{n\theta}{n} = \theta.$$

Usamos que $T_{per} \sim \text{Binomial}(n, \theta)$, por lo que $\mathbb{E}[T_{per}] = n\theta$.

► **Varianza:**

$$\text{Var}(\hat{\theta}_{per}) = \text{Var}\left(\frac{T_{per}}{n}\right) = \frac{1}{n^2} \text{Var}(T_{per}) = \frac{n\theta(1-\theta)}{n^2} = \frac{\theta(1-\theta)}{n}.$$

También utilizamos que T_{per} es binomial.

► **Error cuadrático medio (ECM):**

Como el sesgo es cero,

$$\text{ECM}(\hat{\theta}_{per}) = \text{Var}(\hat{\theta}_{per}) + \mathbb{E}^2(\hat{\theta}_{per}) = \frac{\theta(1-\theta)}{n}.$$

► **Consistencia:**

Observamos que $\hat{\theta}_{per} = \frac{T_{per}}{n} = \frac{1}{n} \sum_{i=1}^n Y_i$,
donde $\mathbb{E}[Y_i] = \theta$ y $\text{Var}(Y_i) = \theta(1 - \theta)$.

Por la Ley Fuerte de los Grandes Números,

$$\hat{\theta}_{per} \xrightarrow{c.s.} \theta.$$

Por lo tanto, $\hat{\theta}_{per}$ es **fuertemente consistente**.

► **Distribución asintótica:**

Por el Teorema Central del Límite,

$$\sqrt{n}(\hat{\theta}_{per} - \theta) \xrightarrow{d} N(0, \theta(1 - \theta)).$$

1.4 Intervalo de confianza para θ

- ▶ Sabemos que por TCL:

$$\sqrt{n} \frac{(\hat{\theta}_{per} - \theta)}{\sqrt{\theta(1-\theta)}} \xrightarrow{d} N(0, 1).$$

- ▶ Además, por ley débil de los grandes números:

$$\hat{\theta}_{per} \xrightarrow{P} \theta$$

- ▶ Entonces, combinando los resultados anteriores con Slutsky:

$$\sqrt{n} \frac{(\hat{\theta}_{per} - \theta)}{\sqrt{\hat{\theta}_{per}(1 - \hat{\theta}_{per})}} \xrightarrow{d} N(0, 1).$$

Como $P(Z \geq 1.96) = 0.025$, vale lo siguiente:

$$P\left(-1.96 \leq \sqrt{n} \frac{\hat{\theta}_{per} - \theta}{\sqrt{\hat{\theta}_{per}(1 - \hat{\theta}_{per})}} \leq 1.96\right) \xrightarrow{n \rightarrow \infty} 0.95.$$

- ▶ Finalmente, se deduce el siguiente intervalo de nivel asintótico 0.95:

$$IC_{0.95}(\theta) = \hat{\theta}_{per} \pm 1.96 \sqrt{\frac{\hat{\theta}_{per}(1 - \hat{\theta}_{per})}{n}}$$

1.5 Cubrimiento empírico

- ▶ Para evaluar el cubrimiento empírico del intervalo dado en 1.4, se llevó a cabo una simulación Monte Carlo para los siguientes valores de n :

10, 20, 50, 100, 1000, 10000

- ▶ Y se obtuvieron estos resultados:

Table 1: Cubrimiento empírico del intervalo

n	cubrimiento
10	0.9232
20	0.8992
50	0.9362
100	0.9462
1000	0.9472
10000	0.9486

- ▶ Los resultados obtenidos son coherentes con la teoría. Al tratarse de un intervalo asintótico, el cubrimiento empírico converge hacia el nivel nominal del 0.95 conforme aumenta el tamaño muestral n .

Parte II

Test imperfecto con S_e y S_p conocidos

2.0.1 Estimación de p con T_{per}

Nuevo escenario

- ▶ Ahora el test **no es perfecto**.
- ▶ Características del test:

$$Se = P(T = 1 \mid Y = 1), \quad Sp = P(T = 0 \mid Y = 0).$$

- ▶ El resultado observado del test se llama T (1 = positivo, 0 = negativo).
- ▶ En este punto definimos:

$$p = P(T = 1)$$

es decir, la **probabilidad de que el test dé positivo**.

Datos observados

- ▶ Tomamos una muestra de tamaño n .
- ▶ Para cada individuo observamos el resultado del test:

$$T_1, T_2, \dots, T_n \sim \text{i.i.d. Bernoulli}(p).$$

- ▶ Definimos:

$$T_{per} = \sum_{i=1}^n T_i,$$

que ahora representa **la cantidad de tests positivos**, no la cantidad de enfermos reales.

- ▶ Entonces:

$$T_{per} \sim \text{Binomial}(n, p).$$

Construcción del estimador

- ▶ La esperanza de la variable binomial es:

$$E[T_{per}] = np.$$

- ▶ El estimador natural es la proporción de tests positivos observados:

$$\hat{p} = \frac{T_{per}}{n}.$$

2.0.2 p como función de θ , S_e y S_p .

Objetivo

- ▶ Queremos expresar:

$$p = P(T = 1)$$

en función de:

- ▶ la prevalencia verdadera $\theta = P(Y = 1)$,
- ▶ la sensibilidad S_e ,
- ▶ la especificidad S_p .

Paso 1: Probabilidad total

$$p = P(T = 1)$$

Utilizamos proba total:

$$P(T = 1) = P(T = 1 \mid Y = 1)P(Y = 1) + P(T = 1 \mid Y = 0)P(Y = 0).$$

Reemplazamos:

- ▶ $P(T = 1 \mid Y = 1) = Se,$
- ▶ $P(Y = 1) = \theta,$
- ▶ $P(Y = 0) = 1 - \theta,$
- ▶ $P(T = 1 \mid Y = 0) = 1 - Sp.$

Obtenemos:

$$p = Se \cdot \theta + (1 - Sp)(1 - \theta).$$

Forma final

Podemos escribir:

$$p = (Se + Sp - 1) \theta + (1 - Sp).$$

Observaciones

- ▶ La expresión es **lineal en θ** .
- ▶ El coeficiente $(Se + Sp - 1)$ determina la “calidad” del test.
 - ▶ Si $Se + Sp - 1 = 0$, el test **no aporta información** ($p = 1 - Sp$).
 - ▶ Si $Se + Sp - 1 > 0$, el test permite recuperar parte de la prevalencia.
- ▶ El término constante $(1 - Sp)$ es la **probabilidad de falso positivo** cuando $\theta = 0\$$.

¿Qué nos dice esta fórmula?

- ▶ El test puede dar positivo por dos razones:
 1. **Verdadero positivo**: la persona está enferma y el test la detecta.
$$Se \cdot \theta$$
 2. **Falso positivo**: la persona está sana pero el test falla.

$$(1 - Sp)(1 - \theta)$$

- ▶ Por eso, la probabilidad total de test positivo es:

$$p = \text{Verdaderos positivos} + \text{Falsos positivos.}$$

2.0.3 Comportamiento de $p = P(T = 1)$

Recordatorio

- ▶ Tenemos:

$$p = P(T = 1) = Se \cdot \theta + (1 - Sp)(1 - \theta).$$

- ▶ También:

$$p(\theta, Se, Sp) = (Se + Sp - 1)\theta + (1 - Sp).$$

- ▶ En este punto queremos ver cómo cambia p en función de:
 1. θ (prevalencia),
 2. Se (sensibilidad),
 3. Sp (especificidad),

fijando los otros dos parámetros.

Caso (a): variamos θ , fijamos Se y Sp

- ▶ Fijamos:

$$Se = 0.9, \quad Sp = 0.95.$$

- ▶ En función de θ :

$$p(\theta) = Se \cdot \theta + (1 - Sp)(1 - \theta).$$

- ▶ Esto es una **función lineal y creciente** en θ .

- ▶ Valores extremos:

- ▶ Si $\theta \rightarrow 0$:

$$p(\theta) \approx 1 - Sp = 0.05 \quad (\text{sólo falsos positivos}).$$

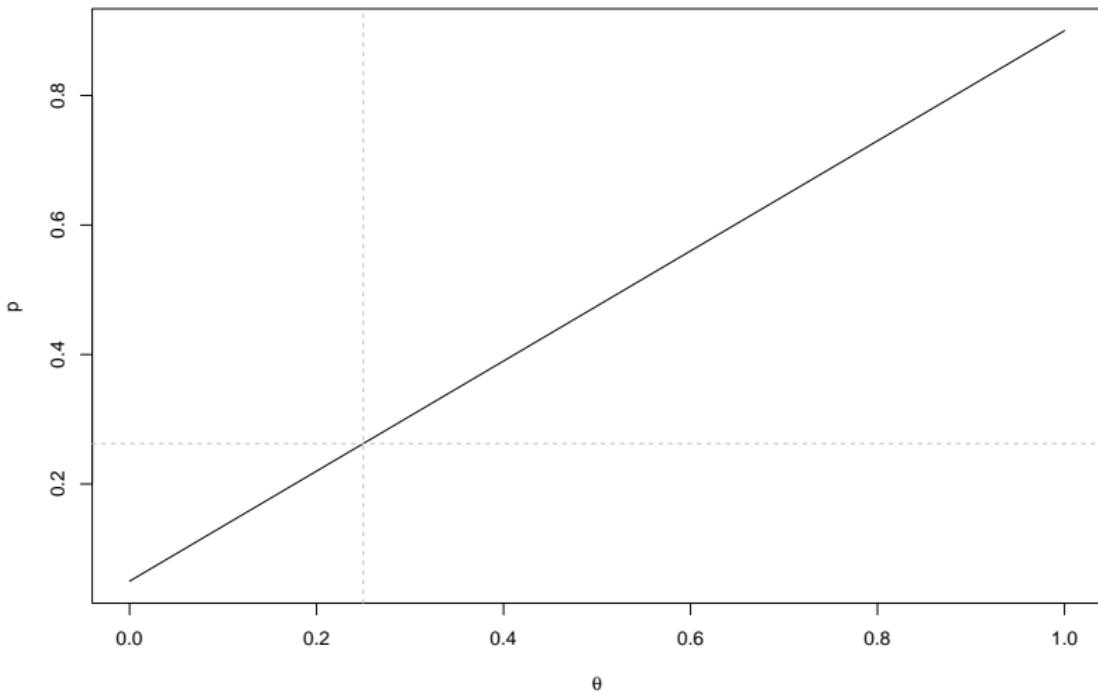
- ▶ Si $\theta = 1$:

$$p(1) = Se = 0.9 \quad (\text{todos enfermos, sólo verdaderos positivos}).$$

- ▶ Para $\theta = 0.25$:

$$p(0.25) = 0.9 \times 0.25 + 0.05 \times 0.75 = 0.2625.$$

Probabilidad de test positivo vs. theta



Caso (b): variamos Se , fijamos θ y Sp

- ▶ Fijamos:

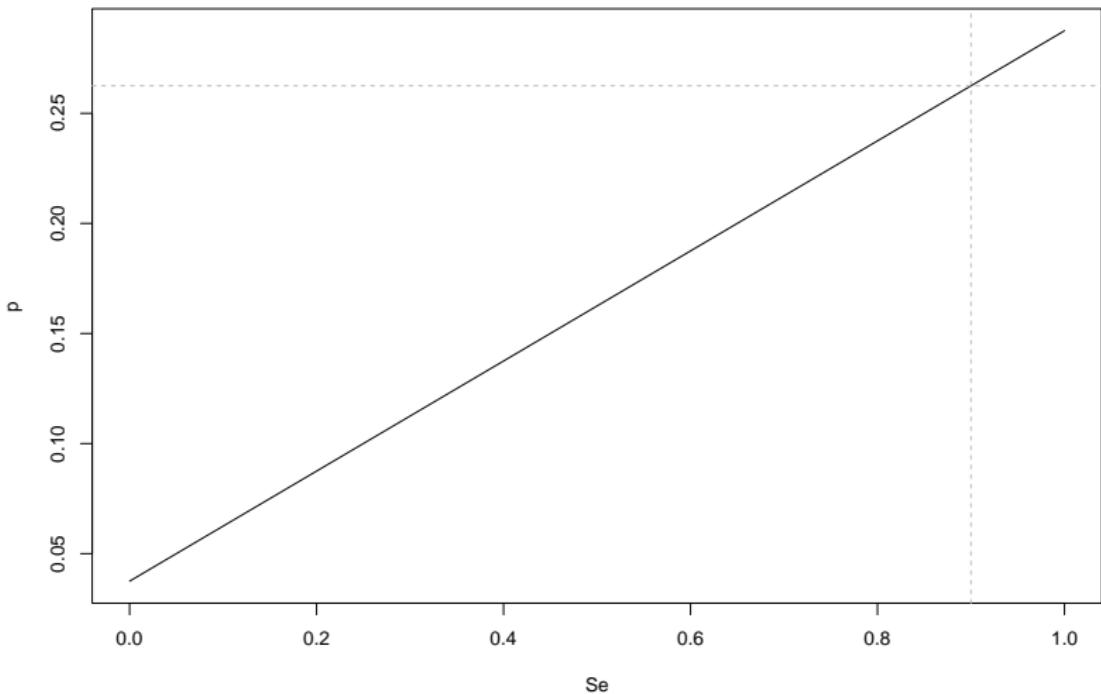
$$\theta = 0.25, \quad Sp = 0.95.$$

- ▶ En función de Se :

$$p(Se) = Se \cdot \theta + (1 - Sp)(1 - \theta) = 0.25 \cdot Se + 0.05 \cdot 0.75.$$

- ▶ Es una función **lineal y creciente** en Se .
- ▶ Interpretación:
 - ▶ Si Se es muy baja, el test casi no detecta enfermos $\rightarrow p$ se mantiene cerca del nivel de falsos positivos.
 - ▶ A medida que aumenta Se , sube la proporción de **verdaderos positivos**, y por eso aumenta p .

Probabilidad de test positivo vs. sensibilidad



Caso (c): variamos Sp , fijamos θ y Se

- ▶ Fijamos:

$$\theta = 0.25, \quad Se = 0.9.$$

- ▶ En función de Sp :

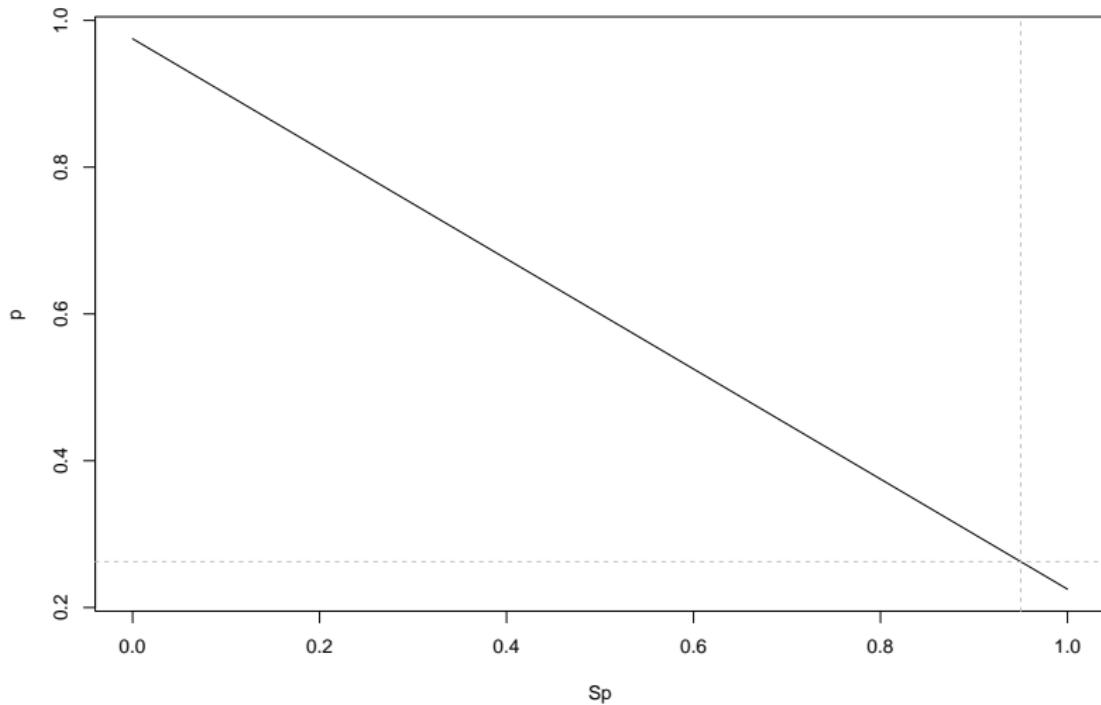
$$p(Sp) = Se \cdot \theta + (1 - Sp)(1 - \theta) = 0.9 \cdot 0.25 + (1 - Sp) \cdot 0.75.$$

- ▶ Es una función **lineal y decreciente** en Sp .

- ▶ Interpretación:

- ▶ Si Sp es baja \rightarrow muchos falsos positivos $\rightarrow p$ es alto, aunque la prevalencia no sea muy grande.
- ▶ Al aumentar Sp , se reducen los falsos positivos \rightarrow disminuye p .

Probabilidad de test positivo vs. especificidad



2.1.4 Estimador de momentos (MoM)

- ▶ Por item 2.0.2, sabemos que:

$$p = S_e \theta + (1 - S_p)(1 - \theta)$$

Reagrupoando:

$$p = (S_e + S_p - 1)\theta + 1 - S_p$$

Entonces:

$$\theta = \frac{p + S_p - 1}{S_e + S_p - 1}$$

- ▶ Como $\mathbb{E}[T_i] = p$, el estimador de momentos de p es
$$\hat{p}_{MoM} = \frac{T_{per}}{n}.$$
- ▶ Finalmente, el estimador plug-in de momentos de θ es el siguiente:

$$\hat{\theta}_{MoM} = \frac{\hat{p}_{MoM} + S_p - 1}{S_e + S_p - 1}$$

2.1.5 Sesgo, varianza y ECM

► Sesgo:

Primero se observa que:

$$\mathbb{E}[\hat{p}_{MoM}] = \mathbb{E}\left[\frac{T_{per}}{n}\right] = p = (S_e + S_p - 1)\theta + 1 - S_p$$

Luego:

$$\mathbb{E}[\hat{\theta}_{MoM}] = \mathbb{E}\left[\frac{\hat{p}_{MoM} + S_p - 1}{S_e + S_p - 1}\right] = \frac{\mathbb{E}[\hat{p}_{MoM}] + S_p - 1}{S_e + S_p - 1} = \theta$$

Por lo tanto $\hat{\theta}_{MoM}$ es un estimador insesgado de θ .

► **Varianza:**

Primero se observa que:

$$\text{Var}[\hat{p}_{MoM}] = \text{Var}\left[\frac{T_{\text{per}}}{n}\right] = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n}$$

Luego:

$$\begin{aligned}\text{Var}[\hat{\theta}_{MoM}] &= \text{Var}\left[\frac{\hat{p}_{MoM} + S_p - 1}{S_e + S_p - 1}\right] = \frac{\text{Var}[\hat{p}_{MoM} + S_p - 1]}{(S_e + S_p - 1)^2} = \\ &\frac{\text{Var}[\hat{p}_{MoM}]}{(S_e + S_p - 1)^2} = \frac{p(1-p)}{n(S_e + S_p - 1)^2}\end{aligned}$$

► **ECM:**

Como el sesgo es 0:

$$\text{ECM}(\hat{\theta}_{MoM}) = \text{Var}[\hat{\theta}_{MoM}] + \mathbb{B}^2[\hat{\theta}_{MoM}] = \frac{p(1-p)}{n(S_e + S_p - 1)^2}$$

► Consistencia

Observemos que, por ley fuerte de los grandes números:

$$\hat{p}_{MoM} = \frac{T_{per}}{n} \xrightarrow{cs} p$$

Luego, como $\hat{\theta}_{MoM}$ es una función continua de \hat{p}_{MoM} :

$$\hat{\theta}_{MoM} \xrightarrow{cs} \frac{p + S_p - 1}{S_e + S_p - 1} = \theta$$

Por lo tanto, $\hat{\theta}_{MoM}$ es fuertemente consistente.

2.1.6 Comparación ECM: Test perfecto vs imperfecto

Fórmulas

$$\text{ECM}_{\text{perfecto}} = \frac{\theta(1 - \theta)}{n}$$

$$\text{ECM}_{\text{imperfecto}} = \frac{p(1 - p)}{n(S_e + S_p - 1)^2}$$

Factor de aumento

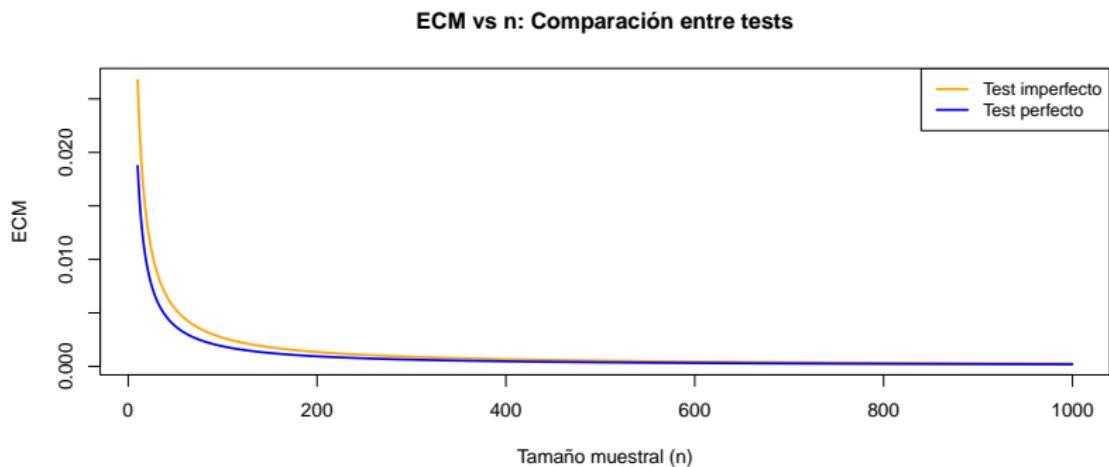
$$\boxed{\frac{1}{(S_e + S_p - 1)^2}}$$

Para $S_e = 0.9$, $S_p = 0.95$

$$S_e + S_p - 1 = 0.85 \Rightarrow \frac{1}{0.85^2} \approx 1.38$$

ECM 38% mayor con test imperfecto

Comportamiento en función de n



Conclusiones clave

Observaciones del gráfico

1. **ECM imperfecto > ECM perfecto** para todo n
2. Ambas **decrecen** como $1/n$

2.1.7 Validación: Teórico vs Simulado

Diseño de simulación

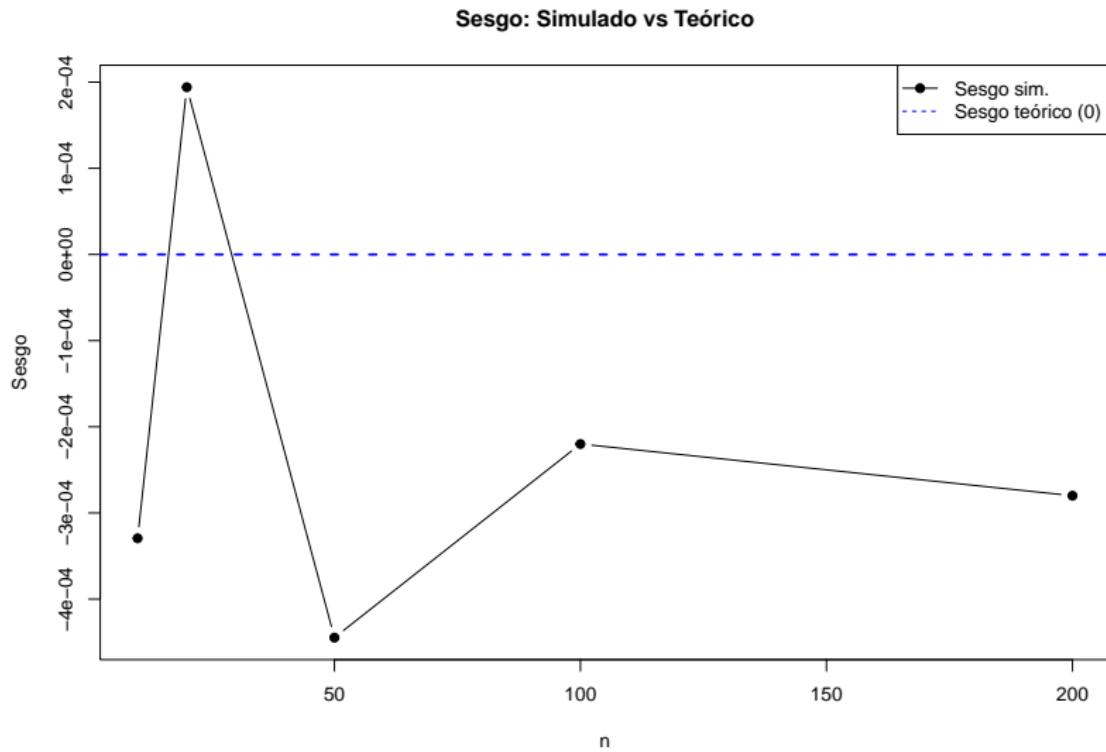
- ▶ $R = 10000$ réplicas
- ▶ $n \in \{10, 20, 50, 100, 200\}$
- ▶ $\theta = 0.25, S_e = 0.9, S_p = 0.95$
- ▶ Estimador: $\hat{\theta}_{MoM}$

Valores teóricos

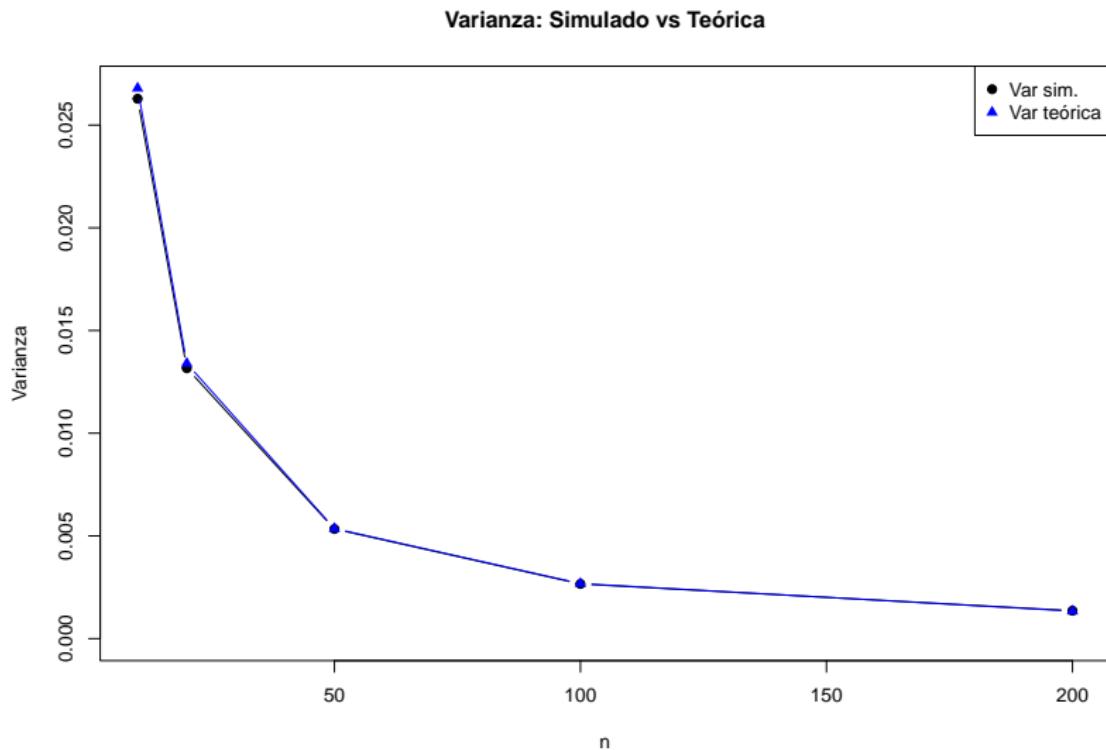
$$\text{Var}_{\text{teórica}} = \frac{p(1-p)}{n(S_e + S_p - 1)^2}$$

$$\text{ECM}_{\text{teórico}} = \text{Var}_{\text{teórica}} \quad (\text{sesgo} = 0)$$

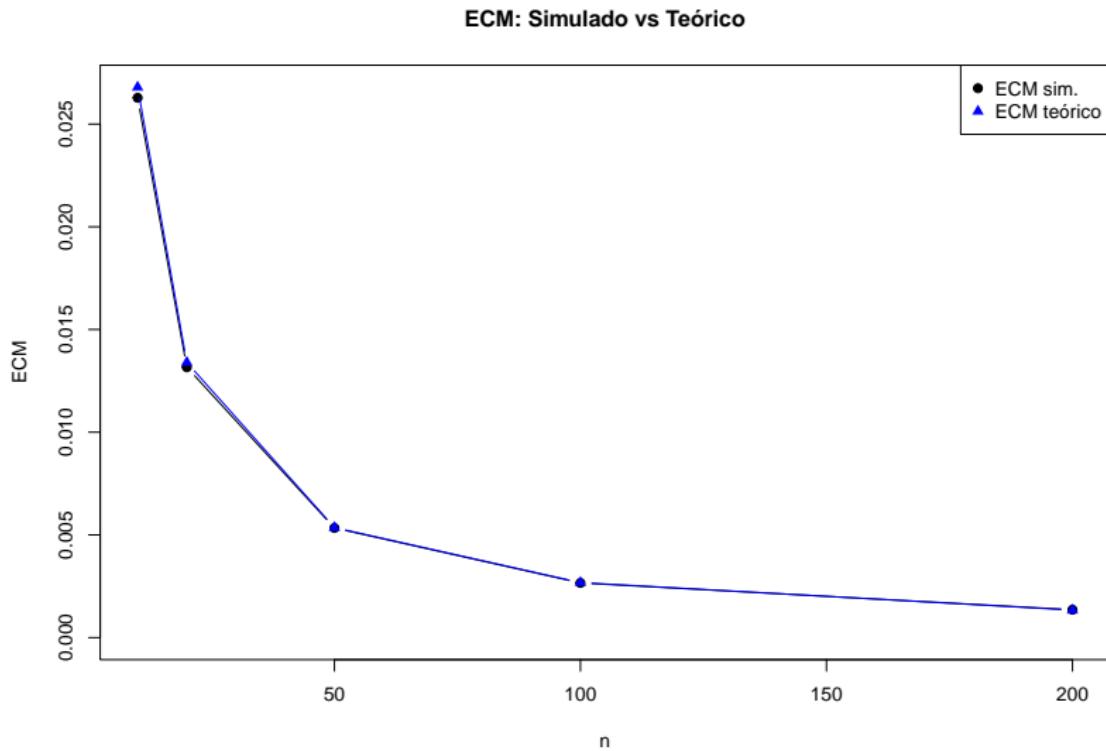
Sesgo: Simulado vs Teórico ($=0$)



Varianza: Simulado vs Teórica



ECM: Simulado vs Teórico



Conclusiones de la validación

Confirmaciones

1. **Sesgo aprox 0** en simulación → Insensibilidad verificada
2. **Varianza simulada aprox Varianza teórica** para todo n
3. **ECM simulada aprox ECM teórico** → Fórmulas correctas

Comportamiento observado

- ▶ **Convergencia:** A mayor n , mejor ajuste entre lo simulado y lo teórico
- ▶ **Consistencia:** Var/ECM decrecen como $1/n$
- ▶ **Robustez:** Fórmulas teóricas válidas aún para n pequeño

Implicaciones

- ▶ **Expresiones teóricas** son confiables
- ▶ **Estimador MoM** se comporta según la teoría
- ▶ **Simulación** valida aproximaciones asintóticas

2.1.8 Bootstrap para $\hat{\theta}_{MoM}$ ($n = 10$)

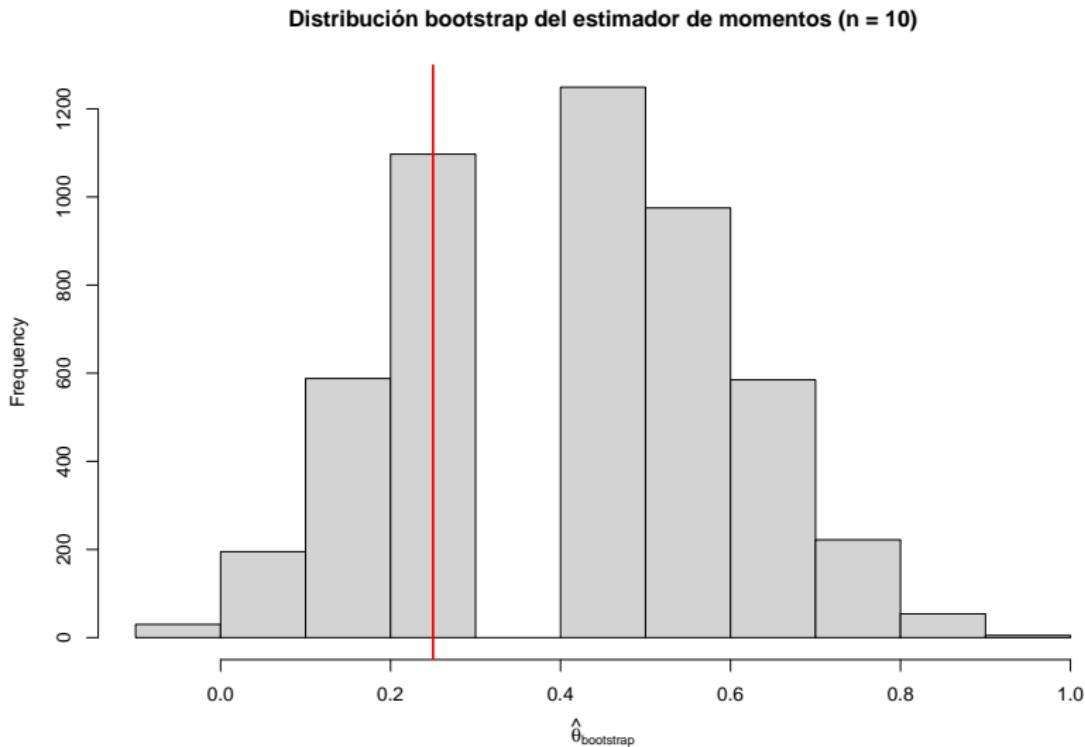
Parámetros

- ▶ $\theta = 0.25$, $S_e = 0.9$, $S_p = 0.95$
- ▶ $n = 10$, $B = 5000$ réplicas bootstrap
- ▶ Bootstrap no paramétrico

Método

1. Muestra original: $T_i \sim \text{Bernoulli}(p)$
2. Remuestreo con reemplazo
3. Recalcular $\hat{\theta}_{MoM}$ en cada réplica

Distribución bootstrap ($n = 10$)



Resultados bootstrap

Estadísticas clave

Media bootstrap = 0.4135

Sesgo bootstrap = 0.1635

Desvío bootstrap = 0.1822

Características observadas

1. **Alta dispersión** (gran variabilidad)
2. **Sesgo positivo**
3. **Distribución asimétrica** hacia derecha
4. **Valores fuera de [0,1]** posibles
5. Se recomienda aumentar n (mas centrado al valor real y disminuir var)

2.2.9 Intervalos de confianza bootstrap

Objetivo

Construir intervalos de confianza para θ basados en el estimador de momentos utilizando bootstrap no paramétrico.

Método

- ▶ A partir de los datos T_i , se calcula $\hat{\theta}_{MoM}$ en cada remuestreo.
- ▶ Se generan $B = 1000$ réplicas bootstrap:
 $\hat{\theta}_{MoM}^{*(b)}$, $b = 1, \dots, B$.
- ▶ Intervalo bootstrap percentil:

$$IC_{0.95}^{boot} = [Q_{0.025}(\hat{\theta}^*), Q_{0.975}(\hat{\theta}^*)].$$

Simulación Monte Carlo

- ▶ Replicaciones: $R = 700$.
- ▶ Tamaños muestrales: $n \in \{10, 20, 50, 100, 1000\}$.
- ▶ Para cada réplica se obtiene:
 - ▶ **Cubrimiento empírico:** $1\{\theta \in IC^{boot}\}$
 - ▶ **Longitud:** $IC^{up} - IC^{low}$

2.2.10 Intervalo de confianza asintótico

Recordemos que:

- ▶ $\hat{p}_{MoM} = \frac{T_{per}}{n}$
- ▶ $\mathbb{E}[\hat{p}_{MoM}] = p$
- ▶ $\text{Var}[\hat{p}_{MoM}] = \frac{p(1-p)}{n}$
- ▶ $\hat{\theta}_{MoM} = \frac{\hat{p}_{MoM} + S_p - 1}{S_e + S_p - 1}$
- ▶ $\mathbb{E}[\hat{\theta}_{MoM}] = \theta$
- ▶ $\text{Var}[\hat{\theta}_{MoM}] = \frac{p(1-p)}{n(S_e + S_p - 1)^2}$

- ▶ Entonces por TCL:

$$\sqrt{n}(\hat{p}_{MoM} - p) \xrightarrow{D} N(0, (p(1-p)))$$

Defino $g(x) = \frac{x+S_p-1}{S_e+S_p-1}$ y $g'(x) = \frac{1}{S_e+S_p-1}$. Notar que $g(x)$ es C^1 .

- ▶ Por Método Delta:

$$\sqrt{n}(g(\hat{p}_{MoM}) - g(p)) \xrightarrow{D} N\left(0, \frac{p(1-p)}{(S_e + S_p - 1)^2}\right)$$

Luego,

$$\frac{\hat{\theta}_{MoM} - \theta}{\sqrt{\text{Var}[\hat{\theta}_{MoM}]}} \xrightarrow{D} N(0, 1)$$

- Además $\hat{p}_{MoM} = \frac{T_{per}}{n} \xrightarrow{cs} p$, entonces:

$$\sqrt{\frac{\hat{p}_{MoM}(1 - \hat{p}_{MoM})}{p(1 - p)}} \xrightarrow{P} 1$$

debido a que $h(x) = \sqrt{\frac{x(1-x)}{p(1-p)}}$ es continua en $(0, 1)$.

Si $\widehat{\text{Var}}[\hat{\theta}_{MoM}] = \frac{\hat{p}_{MoM}(1-\hat{p}_{MoM})}{n(S_e+S_p-1)^2}$, usando teorema de Slutsky:

$$\frac{\hat{\theta}_{MoM} - \theta}{\sqrt{\widehat{\text{Var}}[\hat{\theta}_{MoM}]}} = \frac{\hat{\theta}_{MoM} - \theta}{\sqrt{\text{Var}[\hat{\theta}_{MoM}]}\sqrt{\frac{\hat{p}_{MoM}(1-\hat{p}_{MoM})}{p(1-p)}}} \xrightarrow{D} N(0, 1)$$

- ▶ Por lo tanto, se deduce el siguiente intervalo de nivel asintótico 0.95:

$$IC_{0.95}^\theta = \hat{\theta}_{MoM} \pm 1.96 \sqrt{\widehat{\text{Var}}[\hat{\theta}_{MoM}]}$$

donde $\widehat{\text{Var}}[\hat{\theta}_{MoM}] = \frac{\hat{p}_{MoM}(1-\hat{p}_{MoM})}{n(S_e+S_p-1)^2}$

2.2.11 Comparación entre ambos intervalos

Luego de realizar las simulaciones pertinentes, comparemos los resultados obtenidos.

Table 2: Bootstrap Percentil

n	cubrimiento	longitud_media
10	0.9329	0.5680
20	0.9186	0.4285
50	0.9314	0.2782
100	0.9429	0.2006
1000	0.9514	0.0638

Table 3: Intervalos Asintóticos

n	cubrimiento	longitud_media
10	0.9257	0.5930
20	0.9186	0.4366
50	0.9200	0.2836
100	0.9414	0.2013
1000	0.9457	0.0641

- ▶ El bootstrap parece ser más robusto en muestras pequeñas, lo cual es esperable porque no depende de aproximaciones normales ni del método delta.
- ▶ El método asintótico da intervalos ligeramente más largos.
- ▶ A medida que aumenta n los resultados convergen a los valores esperados.

2.3.12 Comportamiento del estimador de momentos

El estimador puede quedar fuera de $[0, 1]$

Recordemos el estimador de momentos:

$$\hat{\theta}_{MoM} = \frac{\hat{p} + Sp - 1}{Se + Sp - 1}.$$

- ▶ La prevalencia verdadera satisface:

$$0 \leq \theta \leq 1.$$

- ▶ Sin embargo, el estimador $\hat{\theta}_{MoM}$ **NO necesariamente cumple**

$$0 \leq \hat{\theta}_{MoM} \leq 1.$$

¿Por qué ocurre esto?

- ▶ Cuando la muestra es pequeña o el test es poco informativo ($Se + Sp - 1$ cercano a 0), la fórmula puede devolver:
 - ▶ valores **negativos**, o
 - ▶ valores **mayores a 1**.

Ejemplo concreto

Supongamos un test con:

- ▶ $Se = 0.90$
- ▶ $Sp = 0.95$

Entonces:

$$Se + Sp - 1 = 0.90 + 0.95 - 1 = 0.85.$$

Tomemos una muestra donde la proporción de tests positivos es muy baja:

$$\hat{p} = 0.02.$$

Calculemos el estimador de momentos:

$$\hat{\theta}_{MoM} = \frac{\hat{p} + Sp - 1}{Se + Sp - 1} = \frac{0.02 + 0.95 - 1}{0.85} = \frac{-0.03}{0.85} \approx -0.035.$$

Interpretación

- ▶ La prevalencia **no puede ser negativa**, pero el estimador de momentos sí puede producir valores < 0 .
- ▶ Esto sucede porque \hat{p} es muy bajo y el test genera falsos positivos.

2.3.13 Estudio del estimador truncado

Definición del estimador truncado

$$\hat{\theta}_{trunc} = \begin{cases} \hat{\theta}_{MoM}, & 0 \leq \hat{\theta}_{MoM} \leq 1, \\ 0, & \hat{\theta}_{MoM} < 0, \\ 1, & \hat{\theta}_{MoM} > 1. \end{cases}$$

Este estimador **siempre produce valores válidos.**

Queremos estudiar, para $n = 10, 100, 1000$:

1. **Sesgo** de $\hat{\theta}_{trunc}$
2. **Varianza**
3. **ECM**
4. **Distribución aproximada**

Parámetros usados

- ▶ $\theta = 0.25$
- ▶ $Se = 0.90$
- ▶ $Sp = 0.95$

Simulamos N_{rep} réplicas (típicamente 10,000).

Resultados

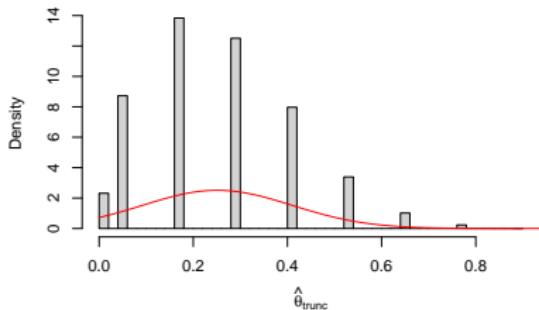
Se obtiene lo siguiente:

Table 4: Resultados

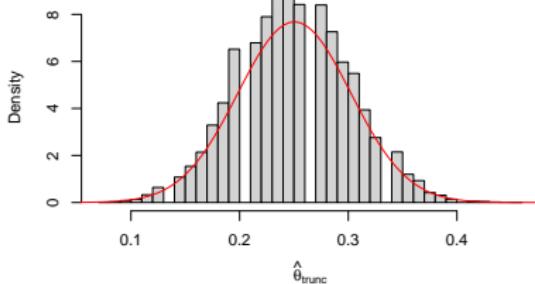
n	media	sesgo	var	ECM
10	0.2485059	-0.001494118	0.024626528	0.024626298
100	0.2500482	0.000048235	0.002685104	0.002684837
1000	0.2500671	0.000067059	0.000262917	0.000262895

- Distribución asintótica: observemos los siguientes gráficos para la distribución asintótica:

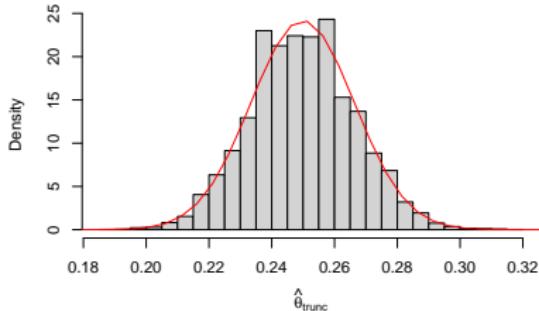
Histograma de $\hat{\theta}_{\text{trunc}}$, $n = 10$



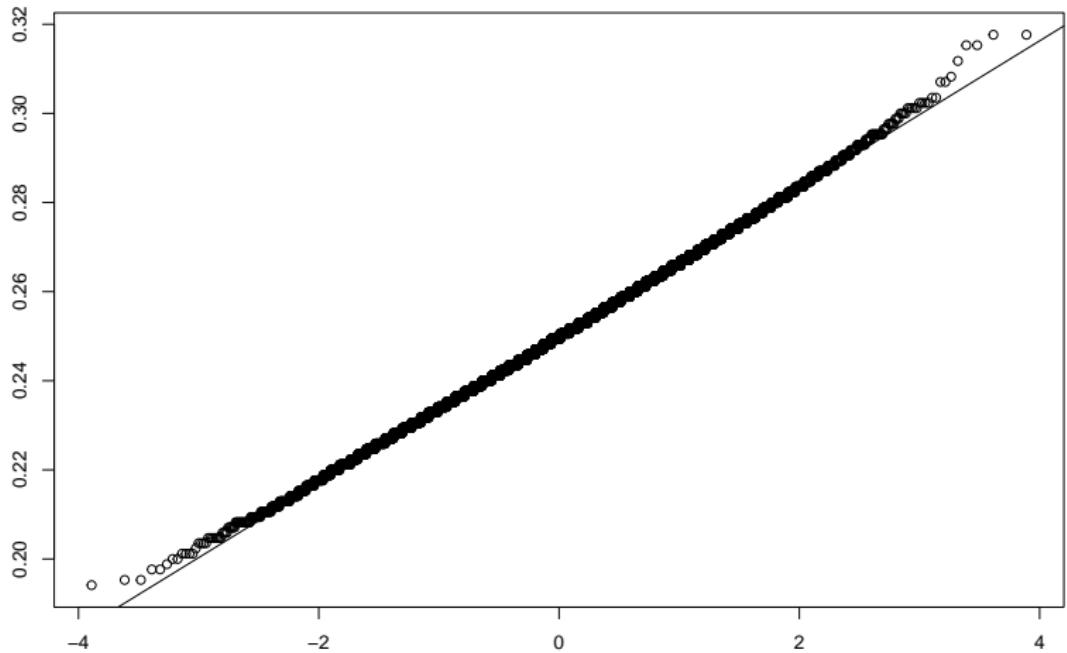
Histograma de $\hat{\theta}_{\text{trunc}}$, $n = 100$



Histograma de $\hat{\theta}_{\text{trunc}}$, $n = 1000$



QQ-plot de $\hat{\theta}_{\text{trunc}}$ para n=1000



Para finalizar, estos resultados, en conjunto, muestran que el truncamiento introduce sesgo en muestras pequeñas, pero el estimador es asintóticamente equivalente al estimador de momentos original, preservando sus propiedades cuando n es grande.

Parte III

Dos muestras (pre-post intervención)

- ▶ En esta sección analizamos si la prevalencia verdadera de la enfermedad cambió después de implementar una campaña de vacunación. Para ello se toman dos muestras independientes:
- ▶ Una **antes** de la campaña, de tamaño n_{pre} , con número de test positivos X_{pre} .
- ▶ Otra **después**, de tamaño n_{post} , con número de test positivos X_{post} .

En ambos casos se utiliza el mismo test diagnóstico imperfecto, caracterizado por su **sensibilidad Se** y **especificidad Sp** .

- ▶ Los conteos observados siguen:

$$X_{\text{pre}} \sim \text{Binomial}(n_{\text{pre}}, p_{\text{pre}}), \quad X_{\text{post}} \sim \text{Binomial}(n_{\text{post}}, p_{\text{post}})$$

donde

$$p_A = (Se + Sp - 1)\theta_A + (1 - Sp), \quad A \in \{\text{pre}, \text{post}\}$$

- ▶ Nuestro objetivo es inferir la **diferencia de prevalencias verdaderas**:

$$\Delta = \theta_{\text{post}} - \theta_{\text{pre}}$$

3.1.1 Test de Hipótesis

Se quiere plantear un test de nivel aproximado 0.05 para las siguientes hipótesis, basándose en el estimador $\hat{\theta}_{MoM}$:

$$H_0 : \Delta = 0 \quad \text{vs.} \quad H_1 : \Delta \neq 0$$

Tenemos:

$$\hat{\theta}_{post} = \frac{\hat{p}_{post} + S_p - 1}{S_e + S_p - 1} \quad y \quad \hat{\theta}_{pre} = \frac{\hat{p}_{pre} + S_p - 1}{S_e + S_p - 1}$$

Y por el item 2.1.10, se deduce que:

$$\hat{\theta}_{post} \approx N(\theta_{post}, \widehat{\text{Var}}(\hat{\theta}_{post})) \quad y \quad \hat{\theta}_{pre} \approx N(\theta_{pre}, \widehat{\text{Var}}(\hat{\theta}_{pre}))$$

$$\Rightarrow \hat{\theta}_{post} - \hat{\theta}_{pre} \approx N\left(\theta_{post} - \theta_{pre}, \widehat{\text{Var}}(\hat{\theta}_{post}) + \widehat{\text{Var}}(\hat{\theta}_{pre})\right)$$

$$U_\Delta(X_{pre}, X_{post}) = \frac{\hat{\theta}_{post} - \hat{\theta}_{pre} - \Delta}{\sqrt{\widehat{\text{Var}}(\hat{\theta}_{post}) + \widehat{\text{Var}}(\hat{\theta}_{pre})}} \approx N(0, 1)$$

- ▶ Tenemos un pivote decreciente en Δ con distribución aproximada conocida independiente de Δ . Entonces, utilizando método del pivote, resulta el siguiente test de nivel aproximado 0.05.

$$\Phi(X_{pre}, X_{post}) = \begin{cases} 1 & \text{si } |U_0(X_{pre}, X_{post})| > z_{1-\alpha/2} = z_{0.975} \approx 1.96, \\ 0 & \text{c.c.} \end{cases}$$

3.1.2 Aplicación en caso ficticio

Vamos a aplicar el test dado en el item anterior a un caso ficticio con $n_{pre} = n_{post} = 100$, $S_e = 0.9$, $S_p = 0.95$, $\theta_{pre} = 0.2$, $\theta_{post} = 0.15$ y $\alpha = 0.05$.

- ▶ El estadístico observado tiene el siguiente valor:

```
## U = -0.3415
```

Por lo tanto, no hay evidencia suficiente como para rechazar H_0 a nivel aproximado 0.05. Esto quiere decir que no se afirma que la vacuna es realmente efectiva. Es razonable porque la diferencia real entre prevalencias es pequeña (0.05).

- ▶ ¿Qué pasa si achicamos la muestra?
- ▶ Para $n = 50$, obtenemos el siguiente resultado:

```
## U (n=50) = 1.1625
```

El valor del estadístico observado sigue estando en la región de aceptación. Igualmente, al haber menos muestras la varianza aumenta y el resultado es distinto de 0.

- ▶ Para $n = 10$, obtenemos el siguiente resultado:

```
## U (n=10) = 0.5199
```

Para una muestra tan pequeña el test se vuelve inestable y es prácticamente inútil, ya que nuestro test es de nivel asintótico.

3.1.3 Intervalo de confianza de nivel asintótico 0.95 para Δ

Usamos el estimador de momentos (no truncado):

$$\hat{\theta}_A = \frac{\hat{p}_A + (Sp - 1)}{Se + Sp - 1}, \quad A \in \{\text{pre, post}\},$$

donde $\hat{p}_A = X_A/n_A$ y X_A es el número de tests positivos observados.

El pivote utilizado es:

$$Z = \frac{\hat{\Delta} - \Delta}{\sqrt{\widehat{Var}(\hat{\theta}_{\text{post}}) + \widehat{Var}(\hat{\theta}_{\text{pre}})}},$$

el cual tiene distribución aproximada $N(0, 1)$.

El intervalo de confianza asintótico al 95% para la diferencia

$$\Delta = \theta_{\text{post}} - \theta_{\text{pre}}$$

es

$$\hat{\Delta} \pm 1.96 \sqrt{\widehat{\text{Var}}(\hat{\theta}_{\text{post}}) + \widehat{\text{Var}}(\hat{\theta}_{\text{pre}})}.$$

donde $\hat{\Delta} = \hat{\theta}_{\text{post}} - \hat{\theta}_{\text{pre}}$.

```
## DeltaHat = 0.1176
```

```
## IC 95% para Delta: [ -0.3259 , 0.5612 ]
```

El intervalo calculado fue:

$$IC_{95\%}(\Delta) = [-0.3259, 0.5612].$$

Observaciones

- ▶ **Incluye al 0**, no hay evidencia suficiente para decir que hay un cambio real entre pre y post.
- ▶ **Intervalo bastante ancho**, hay alta incertidumbre.
- ▶ **Límite superior es bastante grande** puede haber aumento grande entre pre y post.
- ▶ **Límite inferior negativo**, tambien puede haber una disminucion moderada.

3.1.4 Nivel empírico del test.

Se quiere calcular el nivel empírico del test dado en 3.1.2. Para ello, se define una grilla de valores de n para calcular el nivel para cada valor. Se sabe que el nivel de un test está definido por el supremo de los errores de tipo 1. Entonces, también se define una grilla de valores de θ y se realizan las simulaciones pertinentes.

- ▶ Se obtuvieron los siguientes resultados:

Table 5: Nivel empírico del test

n	nivel
10	0.1098
20	0.0895
50	0.0650
100	0.0585
1000	0.0570
10000	0.0595

Se observa claramente el comportamiento asintótico del test. A medida que aumenta n, el nivel del test se acerca a 0.05.